

BITÁCORA DEL PROCESO

Exploración y Comprensión de Datos Abiertos con Microsoft Fabric y Power BI

Actividad 3 — ABP + CDIO | Curso: Visualización de Datos

Nombre / Equipo	Estudiante — Curso Visualización de Datos
Fuente seleccionada	Casos positivos COVID-19 en Colombia — Instituto Nacional de Salud (INS)
URL de la fuente	https://www.datos.gov.co — Portal de Datos Abiertos de Colombia
Fecha de descarga	25 Marzo 2026
Workspace Fabric	lh_covid19_colombia
Lakehouse	lh_covid19_colombia
Docente	Luis Fernando Sánchez Pérez
Duración estimada	13–15 horas

Preguntas Analíticas (3)

#	Pregunta Analítica
P1	¿Cuál es la distribución geográfica de los casos positivos de COVID-19 en Colombia por departamento y municipio, y cuál fue la evolución temporal de la pandemia?
P2	¿Cómo varió el desenlace clínico (Recuperado vs. Fallecido) según variables demográficas como edad, grupo etario, sexo y tipo de contagio?
P3	¿Qué factores de riesgo (edad, sexo, pertenencia étnica) se asocian estadísticamente con una mayor probabilidad de fallecimiento por COVID-19 en Colombia?

Fase C — CONCEBIR

Fecha y duración	Día 1 — Sesión de aprox. 2.5 horas
Herramientas	Navegador web, datos.gov.co, app.fabric.microsoft.com
Objetivo de fase	Seleccionar la fuente, definir el problema analítico, formular las preguntas y explorar el entorno Microsoft Fabric

Actividades Realizadas

- Se exploraron los portales de datos abiertos disponibles: datos.gov.co, Kaggle y datos del Banco Mundial. Después de evaluar múltiples opciones se seleccionó el dataset de casos positivos de COVID-19 en Colombia, gestionado y publicado por el Instituto Nacional de Salud (INS).
- Se verificó que la fuente cumple con todos los criterios de calidad requeridos: más de 1.000 registros (el dataset contiene 1.597.743 filas), 23 variables demográficas, geográficas y clínicas, accesibilidad en formato .csv y licencia de uso educativo.
- Se realizó un análisis previo del dataset (columnas a mantener vs. a eliminar y columnas derivadas a crear) antes de abrir Fabric.
- Se accedió a Microsoft Fabric en <https://app.fabric.microsoft.com> con cuenta educativa Microsoft 365 y se exploró el entorno.
- Se formularon las 3 preguntas analíticas que guiarán el diseño del informe en Power BI (ver portada).

Análisis Previo del Dataset — Decisiones sobre Columnas

Antes de tocar Fabric, se realizó el análisis de las 23 columnas del dataset original para decidir cuáles mantener, cuáles eliminar y cuáles crear como columnas derivadas:

Columnas del dataset original (23 columnas)

Columna Original	Decisión	Justificación
fecha reporte web	✓ Mantener	Permite análisis temporal
ID de caso	✓ Mantener	Identificador único del caso
Fecha de notificación	✓ Mantener	Fecha de reporte oficial
Código DIVIPOLA departamento	✓ Mantener	Código geográfico para joins
Nombre departamento	✓ Mantener	P1: distribución geográfica

Código DIVIPOLA municipio	✓ Mantener	Código geográfico para joins
Nombre municipio	✓ Mantener	P1: distribución geográfica
Edad	✓ Mantener	P2 y P3: demografía
Unidad de medida de edad	✓ Mantener	Necesaria para normalizar Edad
Sexo	✓ Mantener	P2 y P3: demografía
Tipo de contagio	✓ Mantener	P2: desenlace por tipo de contagio
Ubicación del caso	✗ Eliminar	No responde ninguna pregunta analítica
Estado	✗ Eliminar	Redundante con columna 'Recuperado'
Código ISO del país	✗ Eliminar	92% nulos — solo casos importados
Nombre del país	✗ Eliminar	92% nulos — solo casos importados
Recuperado	✓ Mantener	Variable de desenlace clínico (clave P2 y P3) — renombrar a Desenlace
Fecha de inicio de síntomas	✓ Mantener	Análisis de evolución temporal
Fecha de muerte	✓ Mantener	Solo aplica a fallecidos
Fecha de diagnóstico	✓ Mantener	Eje temporal principal
Fecha de recuperación	✓ Mantener	Análisis temporal de recuperación
Tipo de recuperación	✗ Eliminar	Operacional, no responde preguntas analíticas
Pertenencia étnica	✓ Mantener	P3: factor de riesgo étnico
Nombre del grupo étnico	✓ Mantener	Etiqueta legible de pertenencia étnica

Columnas derivadas a crear durante la transformación en Dataflow Gen2

Columna Nueva	Lógica de Creación	Para qué pregunta
Edad_Años	Normaliza Edad a años según Unidad_Edad (1=Años, 2=Meses/12, 3=Días/365)	P2, P3
Grupo_Edad	Rangos etarios desde Edad_Años: 0-17, 18-29, 30-49, 50-64, 65+	P2, P3

Es_Fallecido	1 si Desenlace = 'Fallecido', 0 si no (variable binaria)	P3 — análisis estadístico
Etnia_Descripcion	Decodifica el código numérico de Cod_Etnia a descripción textual	P3
Año_Diagnostico	Extrae el año de Fecha_Diagnostico para filtros temporales	P1, P2
Mes_Num_Diagnostico	Extrae el número del mes de Fecha_Diagnostico	P1
Mes_Nombre	Nombre del mes en español (Enero...Diciembre) a partir de Mes_Num_Diagnostico	P1

Exploración del Entorno Microsoft Fabric y Creación del Workspace

Paso 1.1 — Acceder a Microsoft Fabric

- Se abrió el navegador y se ingresó a <https://app.fabric.microsoft.com>
- Se inició sesión con la cuenta educativa de Microsoft 365.
- En la pantalla de inicio se verificaron todos los workloads disponibles: Lakehouse, Dataflow Gen2, Notebooks de Spark/Python, Power BI y Pipelines.

Paso 1.2 — Crear el Workspace

- En el panel izquierdo se hizo clic en 'Workspaces' (ícono de carpeta).
- Se hizo clic en '+ New workspace'.
- Se completaron los campos: Name: COVID19_Colombia_VizDatos | Description: Proyecto ABP - Análisis de casos COVID-19 en Colombia | License mode (Advanced): Trial.
- Se hizo clic en 'Apply'. El sistema redirigió automáticamente al workspace recién creado.

Justificación de la Selección de la Fuente

- Relevancia temática: La pandemia de COVID-19 es uno de los eventos de salud pública más significativos del siglo XXI. Analizar su evolución en Colombia tiene impacto directo en decisiones de política sanitaria y comunicación de riesgo a la ciudadanía.
- Volumen y riqueza de datos: Con 1.597.743 registros y 23 columnas, el dataset supera ampliamente el mínimo de 1.000 registros. La combinación de variables demográficas, geográficas y clínicas permite un análisis multidimensional robusto.
- Calidad y autoridad de la fuente: Los datos provienen del sistema SIVIGILA del INS, garantizando que son oficiales del Estado colombiano, con trazabilidad desde la notificación hasta el desenlace del paciente.
- Accesibilidad: El dataset está disponible públicamente en datos.gov.co en formato .csv, facilitando su descarga y carga al Lakehouse de Microsoft Fabric.
- Potencial analítico: La presencia de una variable objetivo clara ('Recuperado') sin valores nulos lo hace ideal para análisis descriptivos y de visualización en Power BI.

Dificultades Encontradas y Soluciones

- Dificultad — Tamaño del archivo: El dataset de 1.597.743 filas tiene un peso considerable (~300 MB). Solución: Se verificó la capacidad disponible en la cuenta Trial de Fabric antes de subir el archivo completo.
- Dificultad — Identificación de columnas irrelevantes: Sin leer la guía técnica, habría resultado difícil determinar cuáles de las 23 columnas aportan valor analítico. Solución: Se siguió la tabla de decisiones de la guía completa del proyecto antes de empezar cualquier transformación.

Reflexión: ¿Qué aprendí en esta fase?

La fase de Concepción confirmó que la calidad de un proyecto de análisis de datos depende en gran medida de decisiones tomadas antes de ejecutar cualquier línea de código o transformación. La tabla de decisiones sobre columnas (mantener/eliminar/derivar) es un artefacto crítico: si se omite o se hace a medias, el pipeline ETL y el modelo semántico quedan sin fundamento analítico claro.

También aprendimos que el entorno de Microsoft Fabric no es simplemente una herramienta sino un ecosistema completo que integra almacenamiento (Lakehouse), transformación (Dataflow Gen2), modelado (Semantic Model) y visualización (Power BI) en una sola plataforma y un solo workspace. Entender esta arquitectura desde el principio es clave para no tomar decisiones técnicas que luego generen reprocesos.

Finalmente, formular las 3 preguntas analíticas antes de tocar los datos disciplina el pensamiento: cada decisión técnica posterior (qué columna mantener, qué medida DAX crear, qué visual diseñar) se puede validar preguntando '¿esto responde alguna de mis 3 preguntas?'.

Captura Workspace

The screenshot shows the Microsoft Fabric workspace interface for a project named 'lh_covid19_colombia'. The top navigation bar includes options like 'Nuevo elemento', 'Nueva carpeta', 'Importar', and 'Migrar'. Below this, a central area prompts the user to 'Elija entre flujos de tareas prediseñadas o agregue una tarea para compilar una', with buttons for 'Seleccionar un flujo de tareas prediseñado' and 'Agregar una tarea'. A table at the bottom lists workspace items:

Nombre	Estado	Tipo	Tarea	Propietario	Actualizado	Próxima actualización	Aprobación	Confidencialidad
df_transformacion_covid19	✓	Flujo de dat...	—	MATEO GIR...	6/4/2026, 20:27...	—	—	—
lh_covid19_colombia		Lakehouse	—	MATEO GIR...	—	—	—	—
lh_covid19_colombia		Punto de co...	—	MATEO GIR...	—	—	—	—

Fase D — DISEÑAR


Fecha y duración	Días 2–3 — Sesión de aprox. 4 horas en total
Herramientas	Microsoft Fabric (Lakehouse, Dataflow Gen2), boceto del pipeline
Objetivo de fase	Planificar la arquitectura del pipeline, el esquema de transformaciones ETL y el modelo semántico (esquema estrella)

Actividades Realizadas

- Se definió la estrategia de ingesta del archivo .csv al Lakehouse de Microsoft Fabric.
- Se diseñó el esquema completo de transformaciones del Dataflow Gen2, organizando los pasos en 7 bloques: A) Eliminar columnas, B) Renombrar, C) Cambiar tipos, D) Limpiar texto, E) Manejar nulos, F) Crear columnas derivadas, G) Verificación de calidad.
- Se planificó un segundo Dataflow (df_dimensiones_covid19) para construir las tablas de dimensión del esquema estrella: Dim_Geografía, Dim_Persona y Dim_Fecha.
- Se bocetó la arquitectura final del workspace: Lakehouse con zonas raw y Tables, 2 Dataflows, y el Modelo semántico sm_covid19_colombia.
- Se definieron las relaciones del esquema estrella y las medidas DAX a implementar, clasificadas por pregunta analítica.

Diseño del Pipeline de Ingesta — Arquitectura del Workspace

La arquitectura de datos diseñada sigue el patrón medallion (raw → curated/gold) dentro del Lakehouse de Microsoft Fabric:



Método de ingesta seleccionado: Carga manual del archivo .csv al Lakehouse mediante la opción 'Upload files' en la sección Files > raw. Esta modalidad fue elegida por su simplicidad y confiabilidad con archivos de gran tamaño.

Diseño del Esquema de Transformaciones ETL — Bloques del Dataflow Gen2

Se diseñaron 7 bloques de transformación organizados en orden lógico para el Dataflow df_transformacion_covid19:

Bloque	Tipo de Transformación	Detalle de Acciones
A — Eliminar columnas	Reducción	Eliminar: Código ISO del país, Nombre del país, Estado, Tipo de recuperación, Ubicación del caso (5 columnas)
B — Renombrar columnas	Estandarización	Renombrar las 18 columnas restantes a nombres en formato snake_case sin tildes ni espacios (ej. 'Nombre departamento' → 'Departamento')
C — Cambiar tipos de datos	Tipado	Fechas → Date; Edad, Unidad_Edad, Cod_Etnia → Whole Number; Cod_DIVIPOLA → Whole Number; texto → Text. Limpiar puntos en ID_Caso
D — Limpiar texto	Calidad	Trim + Uppercase sobre columnas Departamento, Municipio, Sexo, Tipo_Contagio, Desenlace, Grupo_Etnico
E — Manejar nulos	Integridad	Fecha_Muerte: mantener nulos (válidos para recuperados). Grupo_Etnico nulos → 'Sin información'. Cod_Etnia nulos → 9
F — Columnas derivadas	Enriquecimiento	Crear 7 columnas: Edad_Anios, Grupo_Edad, Es_Fallecido, Etnia_Descripcion, Año_Diagnostico, Mes_Num_Diagnostico, Mes_Nombre
G — Verificación de calidad	Control	Column profile y Column distribution: verificar valores únicos en Desenlace, Sexo, Es_Fallecido; confirmar conteo de filas igual al original

Renombrado de columnas (Bloque B) — Tabla completa

Nombre Original	Nuevo Nombre
fecha reporte web	Fecha_Reporte
ID de caso	ID_Caso
Fecha de notificación	Fecha_Notificacion
Código DIVIPOLA departamento	Cod_DIVIPOLA_Dpto
Nombre departamento	Departamento
Código DIVIPOLA municipio	Cod_DIVIPOLA_Mpio
Nombre municipio	Municipio
Edad	Edad
Unidad de medida de edad	Unidad_Edad
Sexo	Sexo
Tipo de contagio	Tipo_Contagio
Recuperado	Desenlace
Fecha de inicio de síntomas	Fecha_Inicio_Sintomas
Fecha de muerte	Fecha_Muerte
Fecha de diagnóstico	Fecha_Diagnostico

Fecha de recuperación	Fecha_Recuperacion
Pertenencia étnica	Cod_Etnia
Nombre del grupo étnico	Grupo_Etnico

Diseño del Modelo Semántico — Esquema Estrella

Tabla de Hechos: fact_casos_covid19

Contiene cada registro confirmado de caso positivo de COVID-19 en Colombia, con todas las variables analíticas ya transformadas y las claves foráneas hacia las dimensiones. Es el resultado directo del df_transformacion_covid19.

- Métricas directas: Edad_Anios, Es_Fallecido.
- Variables analíticas: Sexo, Tipo_Contagio, Desenlace, Grupo_Edad, Etnia_Descripcion, Año_Diagnostico, Mes_Nombre.
- Claves foráneas: Cod_DIVIPOLA_Mpio (→ Dim_Geografia), Fecha_Diagnostico (→ Dim_Fecha).

Dimensión 1: dim_geografia

Tabla de ubicaciones únicas por municipio. Se crea en df_dimensiones_covid19 tomando fact_casos_covid19 como fuente, seleccionando solo las columnas geográficas y eliminando duplicados.

- Columnas: Cod_DIVIPOLA_Dpto, Departamento, Cod_DIVIPOLA_Mpio, Municipio.
- Relación con hechos: fact_casos_covid19[Cod_DIVIPOLA_Mpio] → dim_geografia[Cod_DIVIPOLA_Mpio] (Muchos a Uno *:1).

Dimensión 2: dim_persona

Tabla de perfiles demográficos únicos. Se crea en df_dimensiones_covid19 seleccionando Sexo, Grupo_Edad, Cod_Etnia, Etnia_Descripcion, eliminando duplicados y agregando una columna ID_Persona (índice).

- Columnas: ID_Persona, Sexo, Grupo_Edad, Cod_Etnia, Etnia_Descripcion.
- Nota de diseño: Dado que no hay un ID de persona en la tabla de hechos, las columnas demográficas (Sexo, Grupo_Edad, Etnia_Descripcion) se usarán directamente desde la tabla de hechos en los visuales de Power BI.

Dimensión 3: dim_fecha


Tabla de fechas generada con código M en Power Query para el rango 2020-01-01 a 2023-12-31. Esta dimensión habilita la inteligencia de tiempo en DAX (YTD, análisis mensual/trimestral).

- Columnas: Fecha, Año, Mes_Num, Mes_Nombre (en español: es-CO), Trimestre, Semana_Año.
- Relación con hechos: fact_casos_covid19[Fecha_Diagnostico] → dim_fecha[Fecha] (Muchos a Uno *:1).
- Configuración especial: dim_fecha se marcará como 'Date table' (Mark as date table) en el modelo semántico, activando así la inteligencia de tiempo en todas las medidas DAX.

Medidas DAX Planificadas por Pregunta Analítica

Medida DAX	Pregunta	Propósito
Total Casos	P1	Conteo total de registros confirmados
Casos por Departamento	P1	Conteo filtrado por departamento para el mapa
% del Total Nacional	P1	Proporción de cada departamento sobre el total nacional
Total Fallecidos	P2	Conteo de casos con Desenlace = 'Fallecido'
Total Recuperados	P2	Conteo de casos con Desenlace = 'Recuperado'
Tasa de Mortalidad %	P2	$\text{DIVIDE}(\text{Total Fallecidos}, \text{Total Casos}) \times 100$
Tasa de Recuperacion %	P2	$\text{DIVIDE}(\text{Total Recuperados}, \text{Total Casos}) \times 100$
Promedio Edad Fallecidos	P3	Promedio de Edad_Años filtrado por Desenlace = 'Fallecido'
Promedio Edad Recuperados	P3	Promedio de Edad_Años filtrado por Desenlace = 'Recuperado'
Mortalidad por Grupo Edad	P3	Tasa de mortalidad calculada por cada rango etario
Casos con Etnia Registrada	P3	Conteo excluyendo 'Sin información' y 'Sin pertenencia étnica'
Mortalidad Hombres %	P3	Tasa de mortalidad filtrada para Sexo = 'M'
Mortalidad Mujeres %	P3	Tasa de mortalidad filtrada para Sexo = 'F'

Diagrama del Pipeline de Ingesta



Dificultades Encontradas y Soluciones

- Dificultad — Decisión sobre dim_persona: La tabla de dimensión de demografía no tiene una clave foránea natural en la tabla de hechos. Solución: Se definió que las columnas Sexo, Grupo_Edad y Etnia_Descripcion se usan directamente desde fact_casos_covid19 en los visuales de Power BI, y dim_persona sirve como tabla de referencia y documentación del modelo.
- Dificultad — Generación de dim_fecha en M: La generación de una tabla de fechas con nombres de meses en español requiere el parámetro 'es-CO' en Date.ToText(). Solución:

Se documentó la fórmula M completa en la guía técnica para ser copiada exactamente en el Dataflow.

- Dificultad — Alcance de las medidas DAX: Inicialmente se consideraron medidas complejas (análisis de supervivencia, correlaciones). Solución: Se acotaron a las 13 medidas identificadas en la guía, todas alineadas directamente con las 3 preguntas analíticas.

Reflexión: ¿Qué aprendí en esta fase?

La fase de Diseño nos enseñó que la arquitectura de datos bien pensada es el diferenciador entre un proyecto analítico profesional y uno improvisado. La decisión de organizar el workspace con un Lakehouse en zonas raw/curated, dos Dataflows separados (uno para la tabla de hechos y otro para las dimensiones) y un modelo semántico dedicado refleja prácticas reales de la industria de datos.

La tabla de renombrado de columnas (Bloque B) puede parecer trivial, pero es fundamental: los nombres sin tildes, en snake_case y en español comprensible hacen que el informe de Power BI sea interpretable por cualquier stakeholder sin necesidad de consultar el diccionario de datos original.

Aprendimos también que diseñar las medidas DAX antes de construir los visuales es una práctica de ingeniería de datos inversa muy eficiente: primero defines qué métricas necesitas para responder cada pregunta, y luego construyes los visuales que las consumen. Esto evita crear medidas innecesarias o descubrir a último momento que falta una métrica clave.

Fase I — IMPLEMENTAR

Fecha y duración	Días 3–4 — Sesión de aprox. 6 horas en total
Herramientas	Microsoft Fabric (Lakehouse, Dataflow Gen2, Semantic Model), Power BI Desktop
Objetivo de fase	Ejecutar el pipeline en Fabric, transformar los datos y construir el modelo semántico en Power BI con relaciones y medidas DAX

PARTE 2 — Crear el Lakehouse e Ingestar el Archivo

Paso 2.1 — Crear el Lakehouse lh_covid19_colombia

- Dentro del workspace, se hizo clic en '+ New item'.
- En el buscador se escribió 'Lakehouse' y se seleccionó.
- En el campo Name se escribió: lh_covid19_colombia → Create.
- Se verificó la apertura del Lakehouse Explorer con las secciones Files y Tables en el panel izquierdo.

Paso 2.2 — Subir el archivo CSV al Lakehouse

- En el panel izquierdo, se expandió 'Files' → tres puntos (...) → New subfolder → nombre: raw.
- Dentro de la carpeta raw: tres puntos → Upload → Upload files.
- Se seleccionó el archivo casos_covid_19.csv desde el computador.
- Se verificó la presencia del archivo en Files > raw y se tomó captura de pantalla como evidencia.

PARTE 3 — Transformación de Datos con Dataflow Gen2

Paso 3.1 — Crear el Dataflow df_transformacion_covid19

- En el workspace: + New item → Dataflow Gen2 → Nombre: df_transformacion_covid19 → Create.
- Se abrió el editor de Power Query en la nube (interfaz similar a Power Query Desktop).

Paso 3.2 — Conectar la fuente de datos

- En el editor: Get data → buscar 'Lakehouse' → seleccionar Microsoft Fabric Lakehouse.
- Se navegó hasta: workspace → lh_covid19_colombia → Files → raw → archivo CSV.
- Configuración de importación: File origin: UTF-8 | Delimiter: Comma | Data type detection: primeras 200 filas | First row as headers: activado.
- Se confirmó la previsualización con las 23 columnas originales del dataset.

Paso 3.3 — Transformaciones en Power Query (7 Bloques)

```
// BLOQUE A — Eliminar columnas innecesarias
// Ctrl+Click sobre las 5 columnas → clic derecho → Remove columns
// Columnas eliminadas:
//   - Código ISO del país    (92% nulos)
//   - Nombre del país        (92% nulos)
//   - Estado                  (redundante con Recuperado)
//   - Tipo de recuperación   (operacional, no analítico)
//   - Ubicación del caso     (no responde ninguna pregunta)
```

```
// BLOQUE B — Renombrar columnas
// Doble clic en cada encabezado o Transform → Rename column
// Resultado final: 18 columnas renombradas (ver tabla Fase D)
// Ej: 'fecha reporte web' → 'Fecha_Reporte'
//     'Recuperado'        → 'Desenlace'
//     'Pertenencia étnica'→ 'Cod_Etnia'
```

```
// BLOQUE C — Cambiar tipos de datos
// Fechas (ícono tipo → Date — NO Date/Time):
//   Fecha_Reporte, Fecha_Notificacion, Fecha_Inicio_Sintomas,
//   Fecha_Muerte, Fecha_Diagnostico, Fecha_Recuperacion
// Whole Number: Edad, Unidad_Edad, Cod_Etnia, Cod_DIVIPOLA_Dpto
// Text: ID_Caso, Departamento, Municipio, Sexo, Tipo_Contagio,
//       Desenlace, Grupo_Etnico, Cod_DIVIPOLA_Mpio
// NOTA ID_Caso: Transform → Replace Values → '.' → '' (eliminar puntos)
```

```
// BLOQUE D — Limpiar valores de texto
// Seleccionar columnas: Departamento, Municipio, Sexo,
//                       Tipo_Contagio, Desenlace, Grupo_Etnico
// Transform → Format → Trim      (eliminar espacios extra)
// Transform → Format → Uppercase (estandarizar mayúsculas)
// Sexo: valores esperados → 'M' y 'F'
// Desenlace: valores esperados → 'RECUPERADO', 'FALLECIDO', 'ACTIVO', 'N/A'
```

```
// BLOQUE E — Manejar nulos
// Fecha_Muerte: NO tocar — nulos válidos (solo aplica a fallecidos)
// Grupo_Etnico: nulos → 'Sin información'
//   Columna → Transform → Replace Values → (null) → 'Sin información'
// Cod_Etnia:   nulos → 9
//   Columna → Transform → Replace Values → (null) → 9
```

BLOQUE F — Crear columnas derivadas (7 columnas nuevas)

F.1 — Columna Edad_Años (normalizar edad a años):

- Add column → Custom column → Nombre: Edad_Años → fórmula en M:

```
if [Unidad_Edad] = 1 then [Edad]
else if [Unidad_Edad] = 2 then Number.Round([Edad] / 12, 1)
else if [Unidad_Edad] = 3 then Number.Round([Edad] / 365, 1)
else null
// Tipo resultante: Decimal Number
```

F.2 — Columna Grupo_Edad (rangos etarios):

- Add column → Custom column → Nombre: Grupo_Edad → fórmula en M:

```
if [Edad_Años] = null then "Sin dato"
else if [Edad_Años] <= 17 then "0-17 años"
else if [Edad_Años] <= 29 then "18-29 años"
else if [Edad_Años] <= 49 then "30-49 años"
else if [Edad_Años] <= 64 then "50-64 años"
else "65+ años"
// Tipo resultante: Text
```

F.3 — Columna Es_Fallecido (variable binaria para análisis estadístico — P3):

- Add column → Custom column → Nombre: Es_Fallecido → fórmula en M:

```
if Text.Upper([Desenlace]) = "FALLECIDO" then 1 else 0
// Tipo resultante: Whole Number (solo valores 0 y 1)
```

F.4 — Columna Etnia_Descripcion (decodificar código étnico — P3):

- Add column → Custom column → Nombre: Etnia_Descripcion → fórmula en M:

```
if [Cod_Etnia] = 1 then "Indígena"
else if [Cod_Etnia] = 2 then "ROM / Gitano"
else if [Cod_Etnia] = 3 then "Raizal del archipiélago"
else if [Cod_Etnia] = 4 then "Palenquero"
else if [Cod_Etnia] = 5 then "Negro / Afrocolombiano"
else if [Cod_Etnia] = 6 then "Otro"
else if [Cod_Etnia] = 7 then "Sin pertenencia étnica"
else "Sin información"
// Tipo resultante: Text
```

F.5 — Columna Año_Diagnostico:

- Seleccionar Fecha_Diagnostico → Add column → Date → Year → Year → renombrar a Año_Diagnostico. Tipo: Whole Number.

F.6 — Columna Mes_Num_Diagnostico:

- Seleccionar Fecha_Diagnostico → Add column → Date → Month → Month → renombrar a Mes_Num_Diagnostico. Tipo: Whole Number.

F.7 — Columna Mes_Nombre (nombre del mes en español):

- Add column → Custom column → Nombre: Mes_Nombre → fórmula en M:

```
if [Mes_Num_Diagnostico] = 1 then "Enero"
else if [Mes_Num_Diagnostico] = 2 then "Febrero"
else if [Mes_Num_Diagnostico] = 3 then "Marzo"
else if [Mes_Num_Diagnostico] = 4 then "Abril"
else if [Mes_Num_Diagnostico] = 5 then "Mayo"
else if [Mes_Num_Diagnostico] = 6 then "Junio"
else if [Mes_Num_Diagnostico] = 7 then "Julio"
else if [Mes_Num_Diagnostico] = 8 then "Agosto"
else if [Mes_Num_Diagnostico] = 9 then "Septiembre"
else if [Mes_Num_Diagnostico] = 10 then "Octubre"
else if [Mes_Num_Diagnostico] = 11 then "Noviembre"
else "Diciembre"
// Tipo resultante: Text
```

```
// BLOQUE G – Verificación final de calidad
// View → Column profile (activar perfil debajo de cada columna)
//   Desenlace: solo RECUPERADO, FALLECIDO, ACTIVO, N/A
//   Sexo: solo M y F
//   Edad_Años: sin negativos ni valores aberrantes (max ~114)
//   Es_Fallecido: solo 0 y 1
// View → Column distribution: verificar conteo total de filas
//   El número debe coincidir con el archivo .csv original
// Panel Applied Steps: cadena coherente sin pasos duplicados
```

Paso 3.4 — Configurar el destino de la tabla (Output)

- En la parte inferior del editor Dataflow: panel 'Data destination' → Add data destination → Lakehouse.
- Se navegó hasta: workspace → lh_covid19_colombia.
- Table name: fact_casos_covid19 | Método de escritura: Replace.
- Se hizo clic en 'Save settings'.

Paso 3.5 — Publicar el Dataflow

- Clic en 'Publish' (esquina inferior derecha). El proceso tomó entre 5 y 10 minutos.
- Cuando el ícono cambió a check verde, se confirmó la finalización. Se tomó captura de pantalla del estado completado.
- Se navegó al Lakehouse → sección Tables → se verificó la tabla fact_casos_covid19 recién creada.
- Se hizo clic sobre la tabla para previsualizar los datos transformados. Se tomó captura de pantalla.

Explorador

Configuración

fact_casos_covid19

Vista previa de datos - fact_casos_covid19

Mostrando 1000 filas

Buscar

	Fecha_Re...	ABC ID_Caso	Fecha_N...	123 Cod_DIVI...	ABC Depart...	ABC Cod_DIVI...	ABC Municipio	123 Edad	ABC Unidad_E...	ABC Sexo	ABC Tipo_Con...	ABC Desenlace	Fec
1	2020-09-01 0...	618066	2020-08-31 0...	94	GUAINIA	94.001	PUERTO INIRI...	63	1	M	RELACIONADO	FALLECIDO	2020-08
2	2020-10-20 0...	970645	2020-10-15 0...	17	CALDAS	17.433	MANZANARES	27	1	F	COMUNITARIA	RECUPERADO	2020-10
3	2021-07-02 0...	4290518	2021-06-27 0...	11	BOGOTA	11.001	BOGOTA	42	1	F	RELACIONADO	RECUPERADO	2021-06
4	2021-07-03 0...	4314940	2021-06-27 0...	11	BOGOTA	11.001	BOGOTA	11	1	M	RELACIONADO	RECUPERADO	2021-06
5	2021-07-03 0...	4314945	2021-06-28 0...	11	BOGOTA	11.001	BOGOTA	36	1	F	RELACIONADO	RECUPERADO	2021-06
6	2021-07-03 0...	4315074	2021-06-27 0...	11	BOGOTA	11.001	BOGOTA	42	1	F	RELACIONADO	RECUPERADO	2021-06
7	2021-07-03 0...	4315075	2021-06-27 0...	11	BOGOTA	11.001	BOGOTA	24	1	F	RELACIONADO	RECUPERADO	2021-06
8	2021-07-03 0...	4316772	2021-06-28 0...	11	BOGOTA	11.001	BOGOTA	15	1	M	RELACIONADO	RECUPERADO	2021-06
9	2021-07-04 0...	4345194	2021-06-25 0...	11	BOGOTA	11.001	BOGOTA	32	1	F	RELACIONADO	RECUPERADO	2021-06
10	2021-07-04 0...	4349849	2021-06-26 0...	11	BOGOTA	11.001	BOGOTA	21	1	M	RELACIONADO	RECUPERADO	2021-06
11	2021-07-05 0...	4364222	2021-07-02 0...	11	BOGOTA	11.001	BOGOTA	9	1	M	RELACIONADO	RECUPERADO	2021-06
12	2021-07-05 0...	4364370	2021-07-02 0...	11	BOGOTA	11.001	BOGOTA	41	1	F	RELACIONADO	RECUPERADO	2021-07
13	2021-07-06 0...	4387428	2021-07-01 0...	11	BOGOTA	11.001	BOGOTA	15	1	M	RELACIONADO	RECUPERADO	2021-06
14	2021-07-07 0...	4410550	2021-07-02 0...	11	BOGOTA	11.001	BOGOTA	56	1	M	RELACIONADO	FALLECIDO	2021-06
15	2021-07-07 0...	4410554	2021-07-02 0...	11	BOGOTA	11.001	BOGOTA	23	1	M	RELACIONADO	RECUPERADO	2021-07
16	2021-07-07 0...	4410962	2021-07-01 0...	11	BOGOTA	11.001	BOGOTA	31	1	F	RELACIONADO	RECUPERADO	2021-06
17	2021-07-07 0...	4414636	2021-07-01 0...	11	BOGOTA	11.001	BOGOTA	29	1	F	RELACIONADO	RECUPERADO	2021-06
18	2021-07-08 0...	4433546	2021-07-05 0...	11	BOGOTA	11.001	BOGOTA	23	1	F	RELACIONADO	RECUPERADO	2021-06
19	2021-07-09 0...	4462915	2021-07-02 0...	11	BOGOTA	11.001	BOGOTA	26	1	F	RELACIONADO	RECUPERADO	2021-06
20	2021-07-09 0...	4464782	2021-06-26 0...	11	BOGOTA	11.001	BOGOTA	17	1	F	RELACIONADO	RECUPERADO	2021-06
21	2021-07-09 0...	4465031	2021-07-06 0...	11	BOGOTA	11.001	BOGOTA	12	1	M	RELACIONADO	RECUPERADO	2021-07
22	2021-07-09 0...	4470618	2021-07-06 0...	11	BOGOTA	11.001	BOGOTA	11	1	M	RELACIONADO	RECUPERADO	2021-07

PARTE 4 — Crear el Semantic Model en Power BI

Paso 4.1 — Crear sm_covid19_colombia desde el Lakehouse

- En el Lakehouse lh_covid19_colombia → barra superior → 'New semantic model'.
- Nombre: sm_covid19_colombia.
- Se seleccionaron las 4 tablas: fact_casos_covid19, dim_geografia, dim_persona, dim_fecha → Confirm.

Paso 4.2 — Crear relaciones (vista de modelo)

- Se abrió la vista de diagrama (ícono en el panel izquierdo).

Tabla origen (Many)	Columna	Tabla destino (One)	Columna	Cardinalidad
fact_casos_covid19	Cod_DIVIPOLA_Mpio	dim_geografia	Cod_DIVIPOLA_Mpio	Muchos a Uno (*:1)
fact_casos_covid19	Fecha_Diagnostico	dim_fecha	Fecha	Muchos a Uno (*:1)

- Nota: Dim_Persona no tiene relación directa. Sus columnas se usan directamente desde fact_casos_covid19 en los visuales.

Paso 4.2b — Configurar tabla de fechas

- Clic derecho sobre dim_fecha → 'Mark as date table' → seleccionar columna 'Fecha'.
- Esto activa la inteligencia de tiempo en DAX (YTD, Month over Month, etc.).

Paso 4.3 — Crear medidas DAX

Se crearon las siguientes medidas DAX en la tabla fact_casos_covid19 (New measure desde el menú):

Medidas — Pregunta 1: Distribución geográfica

```
Total Casos = COUNTROWS(fact_casos_covid19)

Casos por Departamento =
CALCULATE(
    COUNTROWS(fact_casos_covid19),
    ALLEXCEPT(fact_casos_covid19, fact_casos_covid19[Departamento])
)

% del Total Nacional =
DIVIDE(
    COUNTROWS(fact_casos_covid19),
    CALCULATE(COUNTROWS(fact_casos_covid19), ALL(fact_casos_covid19)),
    0
)
```

Medidas — Pregunta 2: Desenlace clínico

```
Total Fallecidos =  
CALCULATE(COUNTROWS(fact_casos_covid19),  
    fact_casos_covid19[Desenlace] = "Fallecido")  
  
Total Recuperados =  
CALCULATE(COUNTROWS(fact_casos_covid19),  
    fact_casos_covid19[Desenlace] = "Recuperado")  
  
Tasa de Mortalidad % =  
DIVIDE([Total Fallecidos], [Total Casos], 0) * 100  
  
Tasa de Recuperacion % =  
DIVIDE([Total Recuperados], [Total Casos], 0) * 100  
  
Promedio Edad Fallecidos =  
CALCULATE(AVERAGE(fact_casos_covid19[Edad_Anios]),  
    fact_casos_covid19[Desenlace] = "Fallecido")  
  
Promedio Edad Recuperados =  
CALCULATE(AVERAGE(fact_casos_covid19[Edad_Anios]),  
    fact_casos_covid19[Desenlace] = "Recuperado")
```

Medidas — Pregunta 3: Factores de riesgo

```
Mortalidad por Grupo Edad =  
DIVIDE(  
    CALCULATE(COUNTROWS(fact_casos_covid19),  
        fact_casos_covid19[Desenlace] = "Fallecido"),  
    COUNTROWS(fact_casos_covid19), 0) * 100  
  
Casos con Etnia Registrada =  
CALCULATE(COUNTROWS(fact_casos_covid19),  
    fact_casos_covid19[Etnia_Descripcion] <> "Sin información",  
    fact_casos_covid19[Etnia_Descripcion] <> "Sin pertenencia étnica")  
  
Mortalidad Hombres % =  
CALCULATE(  
    DIVIDE(CALCULATE(COUNTROWS(fact_casos_covid19),  
        fact_casos_covid19[Desenlace] = "Fallecido"),  
        COUNTROWS(fact_casos_covid19), 0) * 100,  
    fact_casos_covid19[Sexo] = "M")  
  
Mortalidad Mujeres % =  
CALCULATE(  
    DIVIDE(CALCULATE(COUNTROWS(fact_casos_covid19),  
        fact_casos_covid19[Desenlace] = "Fallecido"),  
        COUNTROWS(fact_casos_covid19), 0) * 100,  
    fact_casos_covid19[Sexo] = "F")
```

Paso 5.4 — Guardar y publicar el Modelo Semántico

- Clic en 'Save' (Ctrl+S). El modelo semántico quedó publicado dentro del workspace de Fabric.
- El modelo sm_covid19_colombia es accesible desde Power BI Desktop y Power BI Service.

PARTE 5 — Conectar Power BI Desktop al Semantic Model de Fabric

Paso 5.1 — Obtener el Connection String

- En el workspace: clic en sm_covid19_colombia → Settings → Server settings.
- Copiar el campo 'Server' con formato:
powerbi://api.powerbi.com/v1.0/myorg/COVID19_Colombia_VizDatos
- Dataset name: sm_covid19_colombia.

Paso 5.2 — Conectar desde Power BI Desktop

- Abrir Power BI Desktop → Get data → buscar 'Power BI semantic models' → seleccionar.
- Navegar hasta el workspace COVID19_Colombia_VizDatos → seleccionar sm_covid19_colombia → Connect.
- Seleccionar 'Connect live' (los datos se leen en tiempo real desde Fabric — no se duplican localmente).
- Resultado: todas las tablas (fact_casos_covid19, dim_fecha, dim_geografia) y las 13 medidas DAX aparecen en el panel de campos listos para usar en visualizaciones.

Alternativa: usar Power BI Service directamente en Fabric

- Workspace → + New item → Report → Pick a published semantic model → sm_covid19_colombia.
- Se abre el editor de reportes de Power BI Service directamente en el navegador, sin necesidad de Power BI Desktop.

Hallazgos Clave del Análisis Exploratorio Ejecutado

1. Edad como predictor principal

- La edad promedio del dataset es 39.2 años, con un rango de 0 a 114 años. El percentil 75 está en 51 años.
- Mediana de edad para RECUPERADOS: ~35 años. Mediana de edad para FALLECIDOS: ~60 años. Diferencia de 25 años.
- Correlación Edad vs. Recuperado: 0.78 — valor extremadamente alto que confirma que la edad es el predictor dominante de mortalidad.

2. Calidad de datos corregida

Variable	Hallazgo	Acción Aplicada
Sexo	4 categorías por casing: F, M, f, m	Uppercase → 2 categorías: M, F
Desenlace	Variantes de casing y formato	Trim + Uppercase → valores estándar
Grupo_Etnico	>95% nulos — sin información étnica detallada	Nulos → 'Sin información'
Fecha_Muerte	Masivos nulos (normal en recuperados)	Mantenidos como nulos válidos

Duplicados	0 duplicados confirmados	Sin acción requerida
Nulos Estado/Ubicación	36 registros (< 0.003% del total)	Filas eliminadas

3. Columnas derivadas creadas exitosamente

- Edad_Años: edad normalizada a años — rango 0-114, media 39.2. Registros con Unidad_Edad=2 (meses) y =3 (días) correctamente convertidos.
- Grupo_Edad: distribución por rango — el grupo 30-49 años concentra el mayor volumen de contagios, el grupo 65+ años concentra la mayor proporción de fallecidos.
- Es_Fallecido: variable binaria validada — solo valores 0 y 1. Sin nulos.
- Etnia_Descripcion: el código 6 ('Otro') domina con más de 1 millón de registros, confirmando la baja recolección de información étnica.

Dificultades Encontradas y Soluciones

- Dificultad — Rendimiento del Dataflow con 1.5M de filas: Las transformaciones de columnas derivadas (especialmente las fórmulas M con múltiples if-else) generaron tiempos de procesamiento elevados. Solución: Se verificó que la cuenta Trial tuviera capacidad Fabric suficiente y se ejecutó el Dataflow en horario de baja demanda.
- Dificultad — Limpieza del campo ID_Caso con separadores de miles: El dataset original usa puntos como separadores de miles en los IDs (ej. '1.000.003'). Solución: Transform → Replace Values → '.' → " (cadena vacía) antes de cambiar el tipo de dato.
- Dificultad — Creación de la relación con dim_fecha: La columna Fecha_Diagnostico tenía algunos valores nulos que impedían crear la relación con dim_fecha. Solución: Se aplicó un filtro en el Dataflow para excluir filas con Fecha_Diagnostico nula antes de configurar el destino.
- Dificultad — Marcado de dim_fecha como Date table: El modelo semántico no activaba la inteligencia de tiempo hasta marcar la tabla correctamente. Solución: Clic derecho sobre dim_fecha → Mark as date table → seleccionar columna Fecha.

Reflexión: ¿Qué aprendí en esta fase?

La Fase de Implementación fue la más técnicamente exigente y la que más aprendizajes concentró. La diferencia fundamental entre un buen pipeline ETL y uno improvisado no está en la tecnología sino en la disciplina del proceso: seguir los bloques A-G en orden lógico, verificar el estado de los datos después de cada bloque y documentar cada Applied Step en Power Query.

Las columnas derivadas (especialmente Edad_Años, Grupo_Edad y Es_Fallecido) transformaron un dataset de registros crudos en un dataset analíticamente rico. Sin esas columnas, los visuales de Power BI habrían sido genéricos. Con ellas, se pueden responder preguntas como '¿cuál es la tasa de mortalidad en el grupo 65+ años por sexo?', que es exactamente el tipo de análisis que tiene valor en salud pública.

También aprendí el valor arquitectónico del esquema estrella en Power BI: separar los datos en fact_casos_covid19 + dim_fecha + dim_geografia hace que las medidas DAX sean más simples de escribir y que los filtros del informe funcionen correctamente. Un modelo plano (una sola tabla) habría generado problemas de rendimiento y relaciones incorrectas en los visuales cruzados.


Finalmente, las medidas DAX clasificadas por pregunta analítica (P1, P2, P3) facilitan enormemente la construcción del informe en la Fase O: ya no hay que pensar qué métricas crear, solo hay que usarlas en los visuales correctos.

Fase O — OPERAR

Fecha y duración	Día 5 — Sesión de aprox. 3.5 horas
Herramientas	Power BI Desktop, Power BI Service, Microsoft Fabric (Workspace)
Objetivo de fase	Diseñar el informe con los visuales recomendados, publicarlo en Power BI Service y reflexionar sobre hallazgos y aprendizajes

PARTE 6 — Estructura Final del Workspace (Verificación)

Antes de diseñar el informe, se verificó que el workspace contuviera todos los artefactos requeridos:



COVID19_Colombia_VizDatos (Workspace)	✓	
└─ lh_covid19_colombia (Lakehouse)	✓	
└─ Files/raw/casos_covid_19.csv	✓	
└─ Tables/		
└─ fact_casos_covid19	✓	(1.597.707 filas tras limpieza de 36 nulos)
└─ dim_geografia	✓	
└─ dim_persona	✓	
└─ dim_fecha	✓	(1.461 fechas: 2020-01-01 a 2023-12-31)
└─ ⚡ df_transformacion_covid19	✓	(estado: check verde)
└─ ⚡ df_dimensiones_covid19	✓	(estado: check verde)
└─ ◇ sm_covid19_colombia	✓	(2 relaciones activas, 13 medidas DAX)

Publicación del Informe y Verificación

En esta sección, detallamos el proceso de despliegue y la validación técnica del producto final en la nube:


- **Despliegue en Power BI Service:** Realizamos la publicación exitosa del informe interactivo en el workspace **lh_covid19_colombia** dentro del ecosistema de Microsoft Fabric.
- **Verificación de la Interactividad:** Validamos que el filtrado cruzado (*cross-filtering*) entre los visuales de cada página funciona correctamente, permitiendo segmentar por **Año**, **Departamento** y **Sexo** sin pérdida de integridad en los datos.
- **Sincronización del Modelo:** Confirmamos que el Modelo Semántico (**sm_covid19_colombia**) mantiene una conexión en vivo (*Live Connection*) con el Lakehouse, asegurando que cualquier actualización en el origen de datos se refleje automáticamente en el reporte.

Hallazgos Principales del Análisis

Tras la implementación de las 13 medidas DAX y la construcción del tablero interactivo, hemos consolidado los siguientes hallazgos divididos por nuestras preguntas analíticas centrales:

P1: Dinámica Geográfica y Progresión de la Pandemia

- **Dominancia de Centros Urbanos:** El análisis mediante el mapa y el gráfico de rectángulos (*treemap*) revela que la carga epidemiológica se concentró masivamente en los nodos de mayor densidad poblacional y actividad económica. **Bogotá** lidera el registro nacional con aproximadamente **0.35 millones de casos**, seguida por los departamentos de **Antioquia** y **Valle del Cauca**. Esta distribución sugiere que los centros de mayor conectividad fueron los focos críticos de propagación.
- **Comportamiento Estacional y "Olas":** La evolución temporal muestra un pico histórico crítico durante el año **2021**, donde el volumen de contagios superó los **1.1 millones de registros**. Observamos una caída drástica a partir del año 2022, lo cual coincide técnicamente con el avance de los esquemas de inmunización y la transición hacia una fase endémica.



P2: Análisis de Desenlace y Perfil Demográfico

- **Vectores de Transmisión:** El **65.01%** de los contagios totales fueron de origen **comunitario**, mientras que el contagio **relacionado** representó el **34.76%**. Los casos importados fueron estadísticamente marginales (**0.23%**), lo que indica que, una vez establecido el virus, la propagación interna fue el factor determinante.
- **Intersección de Edad y Supervivencia:** Al contrastar las curvas de volumen por edad, identificamos que el grupo de **30 a 49 años** concentra la mayor cantidad de registros totales (especialmente recuperados). Sin embargo, el punto de inflexión crítico ocurre a los **50 años**, donde la proporción de fallecimientos comienza a representar una carga significativa sobre el total de casos del rango etario.


Portada

Pregunta 1


Pregunta 2

Pregunta 3


Tasa de Mortalidad % y Tasa de Recuperación % por Sexo



Total Casos por Tipo_Contagio



Total Recuperados y Total Fallecidos por Edad



P3: Caracterización de Factores de Riesgo Críticos

- **Brecha de Mortalidad Generacional:** Los indicadores KPI revelan una disparidad contundente: el promedio de edad de las personas recuperadas se sitúa en los **30.78 años**, mientras que el promedio de edad de los fallecidos asciende a **61.22 años**. Esta diferencia de más de **30 años** ratifica que la edad avanzada es el predictor de riesgo más agresivo en nuestro dataset.
- **Vulnerabilidad Étnica:** Al analizar la tasa de mortalidad por pertenencia étnica, detectamos niveles de riesgo superiores al promedio nacional en comunidades específicas como los **MOKANA** y **ZENU**, donde la tasa de mortalidad supera el **25%** en los casos reportados. Esto señala posibles brechas en el acceso oportuno a servicios de salud o disparidades socioeconómicas que exacerbaban el impacto del virus en estas poblaciones.

Portada

Pregunta 1

Pregunta 2

Pregunta 3

31

Promedio Edad Recuperad...

61

Promedio Edad Fallecidos ...


444 mil

Total Fallecidos

1 mill.

Total Recuperados

Tasa de Mortalidad % por Grupo_Etnico



Limitaciones del Análisis

Para mantener el rigor académico del proyecto, identificamos las siguientes limitaciones externas a nuestro procesamiento técnico:

- **Inconsistencia en la Recopilación Étnica:** Una vasta mayoría de los registros cuenta con información étnica insuficiente o nula, lo que podría sesgar las tasas de mortalidad calculadas para grupos minoritarios.
- **Falta de Variables Clínicas de Soporte:** El dataset del INS no incluye historial de comorbilidades (diabetes, hipertensión, afecciones respiratorias previas), lo cual limita nuestra capacidad para realizar un análisis de riesgo multifactorial más exhaustivo.
- **Dependencia de la Capacidad de Reporte Local:** La precisión geográfica depende de la infraestructura de vigilancia epidemiológica de cada municipio. Es probable que existan subregistros en áreas rurales dispersas con menor acceso a pruebas diagnósticas.

Reflexión Final: ¿Qué aprendimos del proceso completo?

El desarrollo de este proyecto bajo las metodologías **ABP + CDIO** nos ha permitido transformar un conjunto masivo de datos crudos en un sistema de inteligencia de negocios robusto y funcional.

- **Competencia Técnica en Fabric:** Hemos logrado dominar el flujo *end-to-end* en Microsoft Fabric, comprendiendo que la eficiencia de un reporte de Power BI nace desde la arquitectura del **Lakehouse** y la disciplina en los bloques de transformación del Dataflow Gen2.
- **Ingeniería del Dato con Propósito:** Aprendimos que la creación de columnas derivadas y medidas DAX no son tareas aisladas, sino respuestas directas a problemas de negocio o salud pública. El diseño de un **Esquema Estrella** fue fundamental para garantizar que nuestras 13 medidas DAX se ejecutaran con alto rendimiento sobre un dataset de más de **1.5 millones de filas**.
- **Resolución y Adaptabilidad:** El proceso nos enfrentó a retos técnicos reales, desde la gestión de nulos hasta la normalización de tipos de datos complejos. La capacidad de diagnosticar estos problemas y ajustar el diseño en tiempo real constituye el aprendizaje más valioso de esta experiencia educativa.

Competencias Técnicas Desarrolladas

- Microsoft Fabric end-to-end: Comprendí la arquitectura completa de una plataforma de analítica moderna: zonas raw/curated del Lakehouse, Dataflow Gen2 como ETL serverless en la nube, Semantic Model como capa semántica centralizada, y Power BI Service como capa de consumo visual. Todo integrado en un solo workspace.
- ETL con Dataflow Gen2: Aprendí que la organización de transformaciones en bloques lógicos (A-G) no es solo una convención pedagógica — es una práctica de ingeniería que hace el pipeline reproducible, auditable (Applied Steps) y fácilmente mantenible.
- Diseño de modelos semánticos: El esquema estrella con `dim_fecha` marcada como Date Table y las 13 medidas DAX clasificadas por pregunta analítica es un modelo semántico

que cualquier analista de Power BI podría tomar y extender sin necesidad de explicación adicional.

- Fórmulas M avanzadas: La generación de `dim_fecha` con código M (`List.Dates`, `Date.ToText` con `'es-CO'`) y las columnas derivadas con lógica condicional anidada (`Edad_Anios`, `Grupo_Edad`, `Etnia_Descripcion`) superaron el nivel de uso básico del editor visual.

Competencias Transversales Desarrolladas (ABP + CDIO)

- Pensamiento analítico estructurado: El ciclo CDIO obligó a planificar antes de ejecutar. Cada decisión en Diseño (qué columnas eliminar, qué derivadas crear, qué medidas DAX definir) se validó contra las 3 preguntas analíticas formuladas en Concebir.
- Documentación técnica reflexiva: Esta bitácora no es solo un log de pasos ejecutados. Es la evidencia del razonamiento detrás de cada decisión técnica — por qué se eliminaron 5 columnas específicas, por qué `dim_fecha` necesita ser marcada como Date Table, por qué `Edad_Anios` requiere un tratamiento especial.
- Resolución de problemas en tiempo real: Los errores encontrados (puntos en `ID_Caso`, nulos que bloquean relaciones, tiempos de Dataflow) no se podían anticipar completamente en el diseño. La capacidad de diagnosticar, buscar en Microsoft Learn y aplicar la corrección correcta es la competencia más valiosa de esta actividad.